У даній роботі було проведено дослідження задачі автоматичного розпізнавання мовлення на основі аудіоданих з відповідними текстовими транскрипціями. Використаний датасет Toronto містить аудіозаписи українською мовою, що представляють собою природне мовлення з характерними для нього особливостями. Тексти включають розмовні конструкції, власні назви, абревіатури, а також випадки змішування мов, що ускладнює задачу розпізнавання. Додатково, дані можуть містити шум, варіативність вимови та неоднорідність записів, що негативно впливає на якість моделей .

Для розв'язання задачі було використано підхід на основі попередньо натренованої encoder-decoder моделі типу Whisper, яка виконує перетворення аудіосигналу у текстову послідовність. У рамках роботи було проведено два етапи експериментів:

- оцінювання якості базової (бейзлайн) моделі без додаткового навчання;
- донавчання моделі (fine-tuning) на цільовому датасеті з подальшим повторним тестуванням.

На першому етапі базова модель застосовувалась без змін до тестового набору даних. Це дозволило отримати початкові значення метрик якості та визначити рівень, від якого відштовхується подальше покращення. Такий підхід є важливим, оскільки дає змогу об'єктивно оцінити ефективність донавчання.

Результати тестування для бейзлайну:

Baseline WER: 28.93%

Baseline CER: 13.00%

Sample predictions:

REF : музичногостросоціальне святослав вакарчук та альона альона випустили спільний трек країна дітей присвячений дітям

PRED: музичногостру соціальне світаслава керчук та аліона альона випустили спільний трек країна дітей присвячений дітям

REF : які постраждали від війни на сході україни збройних конфліктів та терактів діти які які

PRED: які постраждали від війни на сході україни зброїних конфліктів та терактів

REF : пророслиииии в нееебо країни це справді достойна робота на важливу для україни тему і нам здається несправедливим

PRED: це справді достойна робота наважливу для україни тему і нам здається несправедливе

REF : що це відео трішки повільно набирає перегляди тому наполегливо радимо подивитися мимоволі навіть радієш що святослав вакарчук

PRED: мимо волі навіть радіїш що святослава картюк

REF : нарешті навчився писати тексти без дієслівних рим але потім дізнаєшся що слова вакарчука написав сергій жадан

PRED: нарешті навчився писати тексти без дії слівних риб але потім дізнаєшся що слова вакарчука написав сергій жадан

На другому етапі було виконано донавчання моделі. У процесі навчання здійснювався моніторинг метрик по епохах, що дозволило відстежувати динаміку навчання моделі. Зокрема, аналізувались зміни функції втрат (loss) та метрик точності на валідаційному наборі. Спостереження показали поступове зменшення втрат і стабілізацію якості моделі після кількох епох, що свідчить про збіжність процесу навчання.

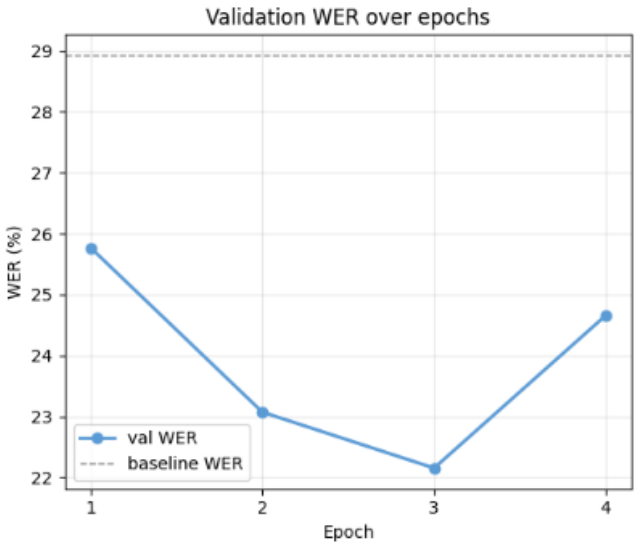

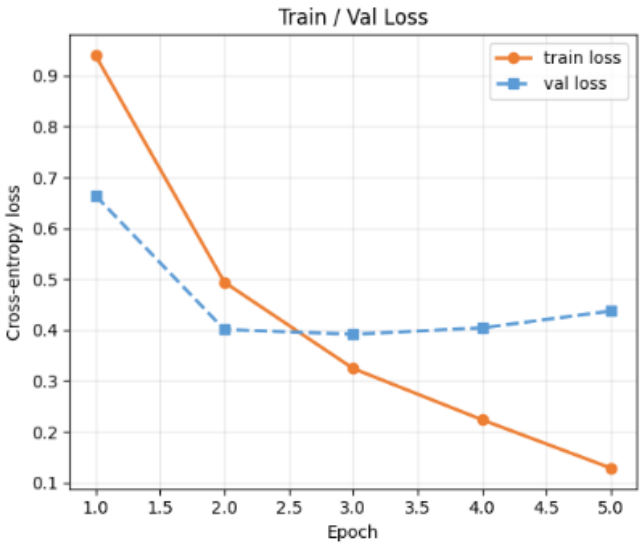

Аналіз динаміки навчання по епохах показує, що найбільше покращення відбувається на початкових етапах навчання, після чого приріст якості поступово зменшується. Це є типовою поведінкою для задач машинного навчання і свідчить про те, що модель швидко адаптується до основних закономірностей даних, але подальше покращення потребує більш складних підходів.

Після завершення навчання модель застосовувалась до тестового набору даних, де генерувались текстові передбачення на основі аудіо. Для контролю довжини відповіді використовувався параметр max_new_tokens. Оцінювання якості здійснювалось без додаткової постобробки результатів, що дозволяє об’єктивно оцінити базову якість моделі.

Результати тестування для дотренованої моделі:

Fine-tuned WER : 24.83%

Fine-tuned CER : 8.50%

Sample predictions:

REF : музичногостросоціальне святослав вакарчук та альона альона випустили спільний трек країна дітей присвячений дітям

PRED: музичногостру соціальне світаслава керчук та аліона аліона випустили спільний трек країна дітей присвячений дітям

REF : які постраждали від війни на сході україни збройних конфліктів та терактів діти які які

PRED: які постраждали від війни на сході україни зброїних конфліктів та терактів тіти які

REF : пророслиииии в нееебо країни це справді достойна робота на важливу для україни тему і нам здається несправедливим

PRED: правді вне по країни це справді достойна робота наважливу для україни тему і нам здається несправедливе

REF : що це відео трішки повільно набирає перегляди тому наполегливо радимо подивитися мимоволі навіть радієш що святослав вакарчук

PRED: що це відео трішки повільно набирає перегляди тому наполегливо радимо подивитися мимо волі навіть радієш що святослав бакарчук

REF : нарешті навчився писати тексти без дієслівних рим але потім дізнаєшся що слова вакарчука написав сергій жадан

PRED: ми реште навчився писати тексти без дії слівних рив але потім дізнаєшся що слова вакарчука написав сергій жадан

Отримані результати показали, що після донавчання модель демонструє покращення порівняно з бейзлайн-версією. Значення метрики Word Error Rate (WER) зменшилось, що свідчить про підвищення точності на рівні слів. Аналогічно, Character Error Rate (CER) також знизився, що вказує на покращення точності на рівні символів. Це підтверджує ефективність адаптації моделі до конкретного датасету.

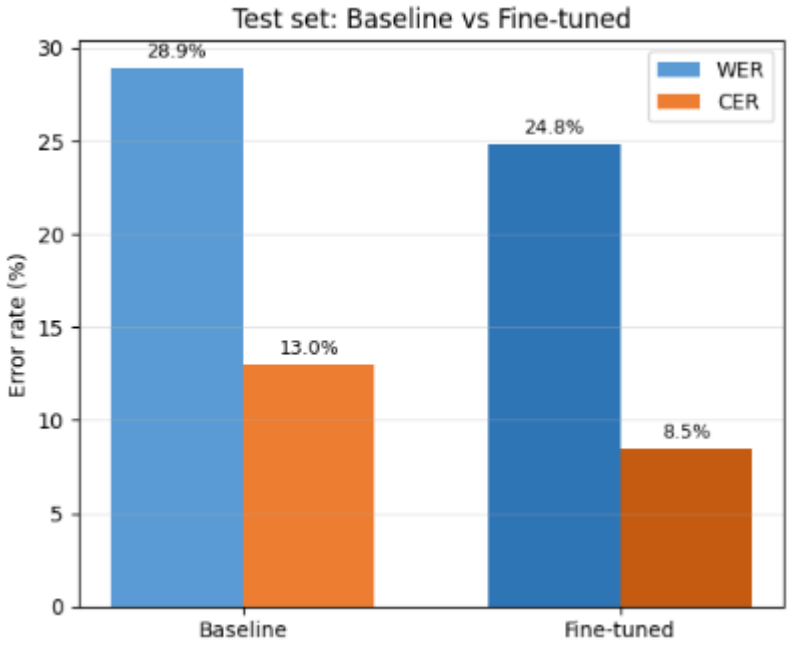

Серед характерних помилок можна виділити спотворення складних або рідковживаних слів, неправильне розпізнавання власних назв та абревіатур, а також помилкову пунктуацію. Це свідчить про те, що навіть після донавчання модель не повністю враховує специфіку предметної області.

Отримані результати можна пояснити кількома факторами. По-перше, обсяг та якість датасету можуть бути недостатніми для повноцінного навчання моделі на всіх мовних особливостях. По-друге, відсутність нормалізації текстів (зокрема, приведення до єдиного формату пунктуації та регістру) ускладнює навчання. По-третє, використання стандартного декодування без розширених стратегій (наприклад, beam search) обмежує якість генерації. Також важливим фактором є багатомовність даних, яка створює додаткове навантаження на модель.

Загалом, результати експерименту демонструють, що донавчання моделі дозволяє суттєво покращити якість розпізнавання порівняно з бейзлайн-моделлю. Модель добре відтворює акустичні характеристики мовлення та показує задовільні результати на рівні символів, однак усе ще має обмеження у точному відтворенні лексики. Для подальшого покращення доцільно збільшити

обсяг навчальних даних, застосувати попередню обробку текстів, використати більш складні методи декодування, а також розглянути можливість додаткової адаптації мовної моделі під українську мову.

Summary:

```
==================================================
FINAL SUMMARY
==================================================
Model : openai/whisper-small
Train : 4434 samples (17 groups)
Val   : 465 samples (2 groups)
Test  : 1736 samples (21 groups)

Metric         Baseline   Fine-tuned      Delta
----------------------------------------------
WER              28.93%       24.83%     -4.10 pp
CER              13.00%        8.50%     -4.50 pp
==================================================
```